

## Vaje pri Statistiki 2

### 1. PRVE VAJE (6. 10. 2022)

**Naloga 1.** Zanima nas povprečni volumen kave espresso, ki jo dobimo v domačem lokalu. Naročimo kavo, izmerimo volumen, označimo ga z  $X$ .

$$X \sim N(\mu, \sigma^2)$$

Eksperiment ponavljamo in dobimo slučajni vzorec  $X_1, \dots, X_n$ . Želimo oceniti  $\mu$  in  $\sigma^2$  z metodo momentov in metodo največjega verjetja.

**Rešitev 1.** Kolikor imamo parametrov toliko momentov moramo poračunati.

$$m_i = E(X_i) \dots i\text{-ti moment}$$

Če želimo oceniti karakteristiko  $q$  jo najprej izrazimo kot funkcijo momentov

$$q = q(m_1, \dots, m_r)$$

Njena cenilka po metodi momentov je ista funkciji vzorčnih momentov  $\hat{q} = q(\hat{m}_1, \dots, \hat{m}_n)$ , kjer je  $\hat{m}_k = \sum_{i=1}^n X_i^k$

$$E(X) = \mu$$

$$E(X^2) = \sigma^2 + \mu^2$$

$$\text{var}(X) = E(X^2) - E(X)^2$$

Metoda momentov (MM):

$$m_1 = \mu$$

$$m_2 = \sigma^2 + \mu^2$$

$$\hat{\mu} = \hat{m}_1 = \bar{X}$$

$$\hat{\sigma}^2 = \hat{m}_2 - \hat{m}_1^2 = \bar{X}^2 - \bar{X}^2$$

Dobimo torej:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = \bar{X}^2 - \bar{X}^2$$

Izračunajmo verjetje.

$$L(X_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} / \ln$$

$$L(X_i, \mu, \sigma^2) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}\right)$$

$$l(X_i, \mu, \sigma^2) = n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

$$\begin{aligned}
\frac{\partial l}{\partial \mu} &= \frac{1}{2\sigma^2} \sum_{i=1}^n 2(X_i - \mu) \\
\frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2} \frac{1}{2\pi\sigma^2} 2\pi + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - \mu)^2 \\
\text{i)} \quad \frac{1}{2\sigma^2} \sum_{i=1}^n 2(X_i - \hat{\mu}) \\
\text{ii)} \quad \frac{\mu}{2}\sigma^2 + \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 &= 0 \\
\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 &= -\frac{\mu}{2}\sigma^2 \\
\sigma^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2
\end{aligned}$$

Cenilka ni nepristranska, da dobimo nepristransko moramo deliti z  $n - 1$ .

**Naloga 2.** Predvidevamo, da je vzorec realnih števil realizacija neodvisnih ponovitev s.s. z gostoto

$$f(x, a, \lambda) = \frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-\lambda x}$$

Poišči kompletno zadostno statistiko za  $\nu = (a, \lambda) \in (0, \infty) \times (0, \infty)$ .

**Rešitev 2.**

$$f(\vec{x}, \nu) = C(\nu) e^{<T(\vec{x}, Q\nu)>} h(\vec{x})$$

Zgornja enačba je eksponentna družina. Tisti  $T$  bo zadostna statistika.

$$\begin{aligned}
f(\vec{x}, a, \lambda) &= \prod_{i=1}^n \frac{\lambda^a}{\Gamma(a)} x_i^{a-1} e^{-\lambda x_i} \\
&= \prod_{i=1}^n \frac{\lambda^a}{\Gamma(a)} e^{\ln(x_i^{a-1}) - \lambda x_i} \\
&= \left(\frac{\lambda^a}{\Gamma(a)}\right)^n \prod_{i=1}^n e^{(a-1)\ln x_i} e^{-\lambda x_i} \\
&= \left(\frac{\lambda^a}{\Gamma(a)}\right)^n e^{(a-1) \sum_{i=1}^n \ln x_i} e^{-\lambda \sum_{i=1}^n x_i} \\
&= \left(\frac{\lambda^a}{\Gamma(a)}\right)^n e^{<(a-1, -\lambda), (\sum_{i=1}^n \ln x_i, \sum_{i=1}^n x_i)>}
\end{aligned}$$

Torej:

$$T(x) = \left(\sum_{i=1}^n \ln x_i, \sum_{i=1}^n x_i\right)$$

Gostoto vektorja  $(x_1, \dots, x_n)$  smo zapisali kot eksponentno družino. Kako preverimo, da je kompletna zadostna statistika? Če ima naša eksponentna družina poln rang je ZS tudi KZS.  $Q$  je bijekcija, zato ima eksponentna družina poln rang in zato je  $T$  KZS.

## 2. DRUGE VAJE (13. 10. 2022)

**Naloga 3.** Obravnavamo splošni linearni model

$$X = Z\beta + \epsilon$$

kjer je  $X \in \mathbb{R}$  vektor opazovanj,  $\beta \in \mathbb{R}^d$  vektor parametrov,  $Z \in \mathbb{R}^{n \times d}$  matrika konstant,  $\epsilon \in \mathbb{R}^n$  vektor slučajnih odstopanj, za katerega vedno privzamemo  $E(\epsilon) = 0$ . Zapišemo  $Z = SP$  za matriko  $S \in \mathbb{R}^{n \times d}$  s paroma pravokotnimi stolpci, od katerih so nekateri lahko 0 (na stolpcih matrike  $Z$  izvajamo Gramm-Schmidtovo ortogonalizacijo).  $P$  je zgornje trikotna matrika s pozitivnimi elementi na glavni diagonali. Tedaj je

$$Z^T Z = P^T J P$$

kjer je  $J = \text{diag}(j_1, \dots, j_d)$ ,  $j_i = \|S^i\|^2$ . Za reševanje enačbe  $(Z^T Z)\hat{\beta} = Z^T x$  konstruiramo konkretno rešitev

$$\hat{\beta} = (Z^T Z)^{-1} Z^T x$$

kjer je  $(Z^T Z)^{-1} = P^{-1} J P^{-1}$ .

Za dano matriko  $Z$  in vektor  $X$  skonstruiraj posplošeni inverz  $(Z^T Z)^{-1}$  ter poišči oceno  $\hat{\beta}$ .

Imamo linearni model:  $X = Z\beta + \epsilon$ , v splošnem iščemo cenilko za  $\beta$ .

$$\hat{\beta} = (Z^T Z)^{-1} Z^T x$$

kjer  $(Z^T Z)^{-1}$  predstavlja klasičen inverz ( $Z$  mora imeti poln rang = imeti mora linearno neodvisne stolpce).

Matriko  $Z$  razcepimo na  $Z = SP$  pri čemer uporabimo Gram-Schmidtovo ortogonalizacijo.

Torej želimo  $Z = SP$ :

$$Z = [Z^1, Z^2, \dots, Z^d] \text{ in } S = [S^1, S^2, \dots, S^d]$$

### Gram-Schmidt

Spomnimo se pravokotne projekcije v splošnem:

$$\text{proj}_u v = \frac{\langle u, v \rangle}{\langle u, u \rangle} u, \text{ pri nas je } \langle u, u \rangle = 1$$

$$\begin{aligned} S_1 &= \frac{Z^1}{\|Z^1\|} \\ S_2 &= \frac{Z^2 - \langle Z^2, S^1 \rangle S^1}{\|Z^2 - \langle Z^2, S^1 \rangle S^1\|} \\ S_3 &= \frac{Z^3 - \langle Z^3, S^1 \rangle S^1 - \langle Z^3, S^2 \rangle S^2}{\|Z^3 - \langle Z^3, S^1 \rangle S^1 - \langle Z^3, S^2 \rangle S^2\|} \end{aligned}$$

in tako naprej

Če imamo na primer dva linearno odvisna stolpca  $Z^2 = \lambda Z^1$  potem:

$$Z^2 - \langle Z^2, S^1 \rangle S^1 = 0 \Rightarrow S^2 = 0$$

Kkao bi izgledala matrika  $P$ ?

$$Z = SP = [Z^1, Z^2, \dots, Z^d] = [S^1, S^2, \dots, S^d]P$$

$P$  je zgornje trikotna matrika s pozitivnimi elementi na diagonalni:

$$P = \begin{bmatrix} \text{poz} & * & \cdots & * \\ & \text{poz} & \cdots & * \\ & & \ddots & * \\ & & & \text{poz} \end{bmatrix}$$

Če iz  $S^i$  izrazimo  $Z^i$  dobimo:

$$Z_1 = \|Z_1\|S_1$$

$$Z_2 = \|Z^2 - \langle Z^2, S^1 \rangle S^1\|S^2 + \langle Z^2, S^1 \rangle S^1$$

...

$$Z^j = \text{poz. št. } S^j + \text{lin. komb. } (S^1, \dots, S^{j-1})$$

Torej mora  $P$  izgledat takole:

$$P = \begin{bmatrix} \|Z_1\| & \langle Z^2, S^1 \rangle & \langle Z^3, S^1 \rangle & \cdots \\ & \|Z^2 - \langle Z^2, S^1 \rangle S^1\| & \langle Z^3, S^2 \rangle & \cdots \\ & & \|Z^3 - \langle Z^3, S^2 \rangle S^2 - \langle Z^3, S^1 \rangle S^1\| & \ddots \end{bmatrix}$$

**Opomba 1.** Na diagonali  $P$  je lahko 0, lahko pa na tisto mesto napišemo karkoli, ker se zmnoži s  $S^d$ , ki je itak ničeln.

Implementacija v R:

---

```

1 # norma vektorja
2 norma = function(x){
3   sqrt(sum(x^2))
4 }
5
6 # GRAM-SCHMIDT
7 GS = function(Z){
8   n <- nrow(Z)
9   d <- ncol(Z)
10  S <- matrix(0, nrow = n, ncol = d)
11  P <- matrix(0, nrow = d, ncol = d)
12  # prvi stolpec S samo normiramo
13  # drop = F uporabljamo zato, da se ohrani oblika (rezultat
14  # bo se vedno matrika in ne vektor)
15  S[, 1] = Z[, 1, drop = F] / norma(Z[, 1])
16  P[1, 1] = norma(Z[, 1])
17  for (i in 2:d){
18    S[, i] = Z[, i, drop = F]
19    # odstavljamo pravokotne projekcije
20    for (j in 1:(i-1)){
21      koef = sum(Z[, i] * S[, j]) # skalarni produkt
22      S[, i] = S[, i] - koef * S[, j]
23      P[j, i] = koef
24    }
25    normaS = norma(S[, i])
26    # ce je pripadajoc stolpec enak 0, bo tudi norma enaka 0
27    if (normaS < 1e-10){
28      # na diagonalo P lahko postavimo katerokoli pozitivno stevilo, ker se mnozi
29      # z 0 (preko S)
30      P[i, i] = 1
31    } else {
32      S[, i] = S[, i, drop = F] / normaS

```

```

32     P[i, i] = normaS
33 }
34 }
35 # vrnemo seznam z S in P
36 list(S, P)
37 }
38
39 podatki2 = read.csv("primer2.csv")
40 Z = as.matrix(podatki2[,3:4])
41 X = as.matrix(podatki2[,2])
42 dim(Z)
43 dim(X)
44
45 # Z = S * P
46 S = GS(Z)[[1]]
47 P = GS(Z)[[2]]
48
49 # Preverimo, ce res dobimo Z, ko zmnozimo S in P
50 z = round(S %*% P, 10)
51 Z == z # vse OK :)
52
53 # se konstrukcija cenilke za beta
54 # lahko pa bi J dobili tudi preko norm stolpcev od S
55 J = t(S) %*% S
56 J = round(J, digits = 10)
57 # posplošeni inverz
58 inv_splosni = solve(P) %*% J %*% solve(t(P))
59
60 # cenilka
61 beta_hat = inv_splosni %*% t(Z) %*% X
62 beta_hat

```

---

### 3. TRETJE VAJE (20. 10. 2022)

#### Naloga 4. Linearna regresija

Predpostavimo linearni model

$$x_i = \beta_0 + \beta_1 z_{i1} + \beta_2 z_{i2} + \epsilon_i, \quad i = 1, \dots, n$$

$\epsilon_i$  so neodvisno slušajne spremenljivke, vse porazdeljene po zakonu  $N(0, \sigma^2)$ . Vrednosti vektorjev  $X, Z_1, Z_2$  so v datoteki *primer2.csv*. Poiščite oceno za  $\hat{\beta}$  na tri načine:

- 1)  $\hat{\beta} = (Z^T Z)^{-1} Z^T x$
- 2)  $\hat{\beta} = (Z^T Z)^{-1} Z^T x$
- 3) z uporabo funkcije `lm` v R

Ali se vrednosti ocen ujemajo?

---

```

1 data = read.csv("primer2.csv")
2
3 X = as.vector(data[,2])
4 Z = as.matrix(data[,3:4])
5 # treba dodati stolpec enic
6 z = cbind(1, Z)
7
8 beta_hat = solve(t(z) %*% z) %*% t(z) %*% X
9
10 model1 = lm(x ~ z1 + z2, data=data[,2:4])
11 model1$coefficients

```

---

### Naloga 5. ANOVA z enojno klasifikacijo

Obravnavamo  $m$  neodvisnih skupin, v vsaki od njih ( $1 \leq j \leq m$ ) imamo  $n_j$  neodvisnih meritev, za katere privzamemo, da so porazdeljene kot  $N(\mu + \alpha_j, \sigma_j^2)$ . Mislimo si, da so  $\alpha_j$  majhna števila. Pišimo  $n = \sum_{j=1}^m n_j$  in naj bo

$$X_i = \mu + \alpha_j + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma_j^2) \text{ za } \sum_{k=1}^{j-1} n_k + 1 \leq i \leq \sum_{k=1}^j n_k$$

S primerno izbiro matrike  $Z$  lahko zgornji model zapišemo kot splošni linearni model.

Naj bo  $m = 4, \mu = 2, (\alpha_1, \alpha_2, \alpha_3, \alpha_4) = (0.2, -0.5, 1, 2), (\sigma_1, \sigma_2, \sigma_3, \sigma_4) = (0.05, 1, 0.03, 0.08)$  in  $(n_1, n_2, n_3, n_4) = (25, 30, 25, 27)$ .

Simuliraj vrednosti  $X_i$ ; konstruiraj primerno matriko  $Z$  ter preko splošnega inverza matrike  $Z$  poišči ocene za  $\mu, \alpha_1, \alpha_2, \alpha_3, \alpha_4$ .

---

```

1  m = 4
2  mi = 2
3  alpha = c(0.2, -0.5, 1, 2)
4  sigma = c(0.05, 1, 0.03, 0.08)
5  n = c(25, 30, 25, 27)
6
7  # Z = matrix(0, sum(n), m)
8  # z = cbind(1, Z)
9  Z = matrix(0,0,m)
10
11 for (i in length(n):1){
12   nov_n = n[i]
13   matrika = matrix(0, nov_n, m)
14   nov_stolpec = as.vector(matrix(1, nov_n, 1))
15   matrika[,i] = nov_stolpec
16   print(matrika)
17   Z = rbind(matrika, Z)
18 }
19
20 Z = cbind(1, Z)
21
22 vektor = c(mi, alpha)
23
24 Z %*% vektor
25
26 X = Map(function(x,y,z) rnorm(n=x, mean=y, sd = z), n, mi + alpha, sigma)
27 # library(dplyr)
28 # X = X %>% unlist() %>% as.matrix()

```

---

## 4. ČETRTE VAJE (27. 10. 2022)

**Izrek 1. Gauss-Markov**

Naj za  $\vec{X} = Z\vec{\beta} + \vec{\epsilon}$  velja  $E(\epsilon) = 0$  in  $\text{var}(\vec{\epsilon}) = \sigma^2 I$ . Tedaj ima cenilka  $UZ\vec{\beta}$  med vsemi linearnimi nepristranskimi cenilkami za  $UZ\vec{\beta}$  enakomerno najmanjšo varianco.

**Naloga 6.** Privzemimo model linearne regresije  $Y = X\beta + \epsilon$  kjer  $E(\epsilon) = 0$  in  $\text{var}(\epsilon) = \sigma^2 V$   
Velja

$$v_{ij} = \frac{p^{|i-j|}}{1-p^2}$$

kjer je  $\sigma^2$  neznana konstanta,  $p \in (-1, 1)$  pa znana.

Naj bodo komponente  $Z$  dane z

$$Z_1 = \sqrt{1-p^2}y_1 \text{ in } Z_i = Y_i - py_{i-1}$$

Izračunaj  $\text{var}(Z_i)$  in  $\text{cov}(Z_i, Z_j)$  za  $i \neq j$  in poišči najboljšo linearno nepristransko cenilko za  $\beta$ .

## 5. PETE VAJE - ODPADEJO (3. 11. 2022)

6. ŠESTE VAJE (10. 11. 2022)

7. SEDME VAJE (17. 11. 2022)

8. OSME VAJE (24. 11. 2022)

9. DEVETE VAJE (1. 12. 2022)